

第 15 周 参数的区间估计

15.1 区间估计的基本思想

点估计用一个点(即一个数)估计未知参数。区间估计用一个区间估计未知参数。

例如估计一个人的年龄在 40 至 45 岁之间, 一个人的身高在 1 米 75 至 1 米 80 之间, 估计产品的合格率在 0.95 至 0.98 之间。

区间估计考虑到了估计的误差, 给人们以更大的信任感。区间估计的理论就是用明确的概率语言刻画这种“信任感”的意义, 并给出得到区间估计的具体概率方法。

例15.1.1 样本 X_1, X_2, X_3, X_4 来自正态总体 $N(\mu, 1)$, 样本均值 \bar{X} 是 μ 的一个点

估计, $[\bar{X} - 1, \bar{X} + 1]$ 为 μ 的一个区间估计。计算概率 $P(\bar{X} = \mu)$ 和

$P(\mu \in [\bar{X} - 1, \bar{X} + 1])$ 。

正态总体 $N(\mu, \sigma^2)$:

方差已知, 期望未知(常见) VS 期望已知, 方差未知(罕见)

例15.1.1 样本 X_1, \dots, X_4 来自正态总体 $N(\mu, 1)$, 样本均值 \bar{X} 是 μ 的一个点估

计, $[\bar{X} - 1, \bar{X} + 1]$ 为 μ 的一个区间估计。计算 $P(\bar{X} = \mu)$ 和

$P(\mu \in [\bar{X} - 1, \bar{X} + 1])$ 。

解: $\bar{X} \sim N\left(\mu, \frac{1}{4}\right)$, $\frac{\bar{X} - \mu}{1/2} = 2(\bar{X} - \mu) \sim N\left(0, \frac{1}{4}\right)$, $P(\bar{X} = \mu) = 0$

$$P(\mu \in [\bar{X} - 1, \bar{X} + 1]) = P(\bar{X} - 1 \leq \mu \leq \bar{X} + 1)$$

$$= P(\mu - 1 \leq \bar{X} \leq \mu + 1) = P(-1 \leq \bar{X} - \mu \leq 1)$$

$$= P(-2 \leq 2(\bar{X} - \mu) \leq 2) = \Phi(2) - \Phi(-2) \approx 0.9544$$

区间估计的概率形式

设 $I(X_1, X_2, \dots, X_n)$ 是一个随机区间,

$$\forall \theta \in \Theta, P_{\theta}(\theta \in I(X_1, X_2, \dots, X_n)) \geq 1 - \alpha,$$

称该区间是参数 θ 的一个置信水平为 $1 - \alpha$ ($0 < \alpha < 1$) 的区间估计,

置信水平可以取到的最大值称为置信系数。

例15.1.1 样本 X_1, \dots, X_4 来自正态总体 $N(\mu, 1)$, 随机区间 $[\bar{X} - 1, \bar{X} + 1]$ 为 μ 的

一个区间估计, $P(\mu \in [\bar{X} - 1, \bar{X} + 1]) = \Phi(2) - \Phi(-2) \approx 0.9544$

$$P(\mu \in [\bar{X} - 1, \bar{X} + 1]) \approx 0.9544 > 0.8$$

可以说 $[\bar{X} - 1, \bar{X} + 1]$ 是 μ 的一个置信水平0.8的区间估计,

$[\bar{X} - 1, \bar{X} + 1]$ 是 μ 的一个置信水平0.9544的区间估计, 置信系数为0.9544

区间估计的三种形式

$$P_{\theta}(\theta \in I(X_1, X_2, \dots, X_n)) \geq 1 - \alpha,$$

当 $I = [\hat{\theta}_1(X_1, X_2, \dots, X_n), \hat{\theta}_2(X_1, X_2, \dots, X_n)]$ 时, 称 I 之为 θ 的置信水平为 $1 - \alpha$

(双侧) 置信区间,

当 $I = [\hat{\theta}_L(X_1, X_2, \dots, X_n), +\infty]$ 时, 称 I 之为 θ 的置信水平为 $1 - \alpha$ 单侧置信区间,

$\hat{\theta}_L$ 为 θ 的置信水平为 $1 - \alpha$ 置信下限,

当 $I = [-\infty, \hat{\theta}_U(X_1, X_2, \dots, X_n)]$ 时, 称 I 之为 θ 的置信水平为 $1 - \alpha$ 单侧置信区间,

$\hat{\theta}_U$ 为 θ 的置信水平为 $1 - \alpha$ 置信上限。

例15.1.1 样本 X_1, \dots, X_4 来自正态总体 $N(\mu, 1)$, 随机区间 $[\bar{X} - 1, \bar{X} + 1]$ 是 μ 的一个置信水平 0.9544 的区间估计。

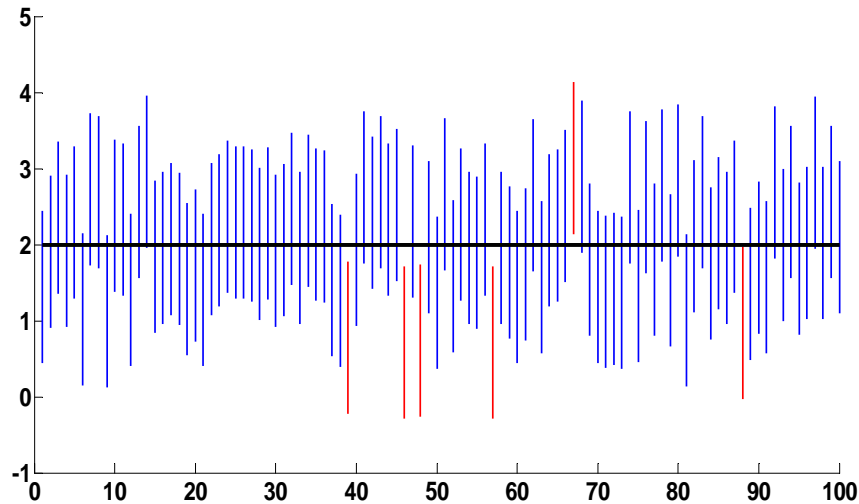


图 15.1

事实上, 未知参数本身是确定的值, 不带有随机性。估计的随机性是由区间引入的。一个置信水平 $1 - \alpha$ 的区间估计, 其含义是: 所得到的随机区间至少以概率 $1 - \alpha$ 覆盖被估的参数。在例 15.1.1 中, 置信水平的含义是: 实际抽取样本容量为 4 的样本得到一次区间估计, 将这样的估计重复足够多次, 那么至少 $1 - \alpha$ 比例的估计区间包含真实的 μ 值。这里置信系数是 0.9544, 即将这一估计方法实际重复足够多次后, 大约 95.44% 的估计区间包含真实的 μ 值。图 15.1 是设定参数 μ 等于 2, 将区间估计重复 100 次的模拟结果, 其中 100 个估计区间中有 6 个区间没有包含 2, 即参数的实际取值, 94% 的区间成功的包含了真实值 μ 等于 2。继续模拟, 将区间估计重复 10000 次, 结果 442 次估计区间没有包含 μ 的真实值 2, 这时成功包含被估参数 μ 等于 2 的区间百分比达到 95.58%。当然, 这些都是概率意义上的结果。具体的每一次估计, 我们不会知道区间是否包含未知参数。

15.2 区间估计的构造方法

区间估计的两个基本要求：

1. 未知参数 θ 要以尽可能大的概率落在区间 $I(X_1, X_2, \dots, X_n)$ 中；
2. 在达到一定的置信水平的前提下，要求区间的长度尽可能小。

参数区间估计枢轴量法实现步骤

步骤1 构造“枢轴量” (pivot) $G(X_1, X_2, \dots, X_n, \theta)$ ， G 的分布不依赖于任何未知参数；

步骤2 适当选取两个常数 c 、 d ，对给定的 α ($0 < \alpha < 1$)，有

$$P(c \leq G \leq d) \geq 1 - \alpha$$

步骤3 求解 $c \leq G(X_1, X_2, \dots, X_n, \theta) \leq d$ ，得到

$$\hat{\theta}_1(X_1, X_2, \dots, X_n) \leq \theta \leq \hat{\theta}_2(X_1, X_2, \dots, X_n)。$$

例 15.2.1 总体 $N(\mu, \sigma^2)$ ， σ^2 已知， μ 未知，简单随机样本 X_1, X_2, \dots, X_n ，求 μ 的 $1-\alpha$ 置信区间。

解： 被估参数 μ 的一个点估计为 $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ ，

$$G = \frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$$

是样本和被估参数 μ 的函数，且 G 的分布不依赖任何未知参数，可作为枢轴量。

$$\text{取适当的常数 } c \text{ 和 } d \text{，使得 } \Phi(d) - \Phi(c) = P\left(c \leq \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \leq d\right) \geq 1 - \alpha，$$

$$\text{取 } d = u_{1-\alpha/2}，c = u_{\alpha/2} = -u_{1-\alpha/2}$$

即得到参数 μ 的 $1-\alpha$ 置信区间 $\bar{X} - u_{1-\alpha/2} \frac{\sqrt{n}}{\sigma} \leq \mu \leq \bar{X} + u_{1-\alpha/2} \frac{\sqrt{n}}{\sigma}$ 。

枢轴量不等式 $P(c \leq G \leq d) \geq 1-\alpha$ 中 c 和 d 的取法

枢轴量为对称分布时

c 和 d 的最优值为 G 的分布函数的 $\frac{\alpha}{2}$ 和 $1-\frac{\alpha}{2}$ 分位点。

当枢轴量的分布为非对称分布时

最优的 c 和 d 可能不易求得，通常也取枢轴量分布的 $\frac{\alpha}{2}$ 和 $1-\frac{\alpha}{2}$ 分位数点。

如在例 15.2.1 中 c 和 d 选取的是最优值，分别为 $d = u_{1-\frac{\alpha}{2}}$ ， $c = -d$ 。

回顾统计抽样定理 设 X_1, X_2, \dots, X_n 是来自正态总体 $N(\mu, \sigma^2)$ 的样本，其样本均值和样本方差分别为 \bar{X} 和 S^2 ，则有

(1) \bar{X} 和 S^2 相互独立，

(2) $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ ，

(3) $\frac{(n-1) \cdot S^2}{\sigma^2} \sim \chi^2(n-1)$ 。

我们在下面构造区间估计的枢轴量的时候，要用到这几个结论。

例 15.2.2 总体 $N(\mu, \sigma^2)$ ， μ 未知， σ^2 未知， X_1, X_2, \dots, X_n 是来自该总体的样本，求 σ^2 的 $1-\alpha$ 置信区间。

解：正态总体的样本方差满足 $\frac{(n-1) \cdot S^2}{\sigma^2} \sim \chi^2(n-1)$

构造枢轴量 $G = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ ，

$$\text{则 } P\left(\chi_{\alpha/2}^2(n-1) \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{1-\alpha/2}^2(n-1)\right) = 1-\alpha,$$

$$\text{所以 } \sigma^2 \text{ 的 } 1-\alpha \text{ 置信区间为 } \left[\frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)} \right].$$

例 15.2.3 总体 $N(\mu, \sigma^2)$, μ 未知, σ^2 未知, X_1, X_2, \dots, X_n 是来自该总体的样本, 求 μ 的 $1-\alpha$ 置信区间。

$$\text{分析: } \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$$

σ 未知, 所以这个标准正态分布随机变量不能作为枢轴量

$$\text{解: 同时考虑 } \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1), \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

正态总体的样本均值 \bar{X} 与样本方差 S^2 相互独立

$$\text{构造 } t \text{ 统计量, } \frac{\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}}{\sqrt{\frac{(n-1)S^2}{\sigma^2} / (n-1)}} = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t(n-1)$$

$$\text{由于 } P\left(t_{\alpha/2}(n-1) \leq \frac{\sqrt{n}(\bar{X} - \mu)}{S} \leq t_{1-\alpha/2}(n-1)\right) = 1-\alpha$$

$$\text{得到 } \mu \text{ 的 } 1-\alpha \text{ 置信区间为 } \left[\bar{X} - \frac{S}{\sqrt{n}} t_{1-\alpha/2}(n-1), \bar{X} + \frac{S}{\sqrt{n}} t_{1-\alpha/2}(n-1) \right].$$

例 15.2.4 假设工厂生产的产品的质量服从正态分布, 估计所生产的产品的平均

质量，现从所生产的产品中抽取 9 件，用一台天平测量，测得结果分别为（单位克）7.32, 7.37, 7.24, 7.41, 7.33, 7.38, 7.36, 7.42, 7.21。

试求产品平均质量的 0.95 置信区间。

解：假设产品的质量服从正态分布 $N(\mu, \sigma^2)$ ，这里 μ 未知， σ^2 未知，

$$\frac{\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}}{\sqrt{\frac{(n-1)S^2}{\sigma^2}}} = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t(n-1), \quad (\text{格赛特, student})$$

$$\mu \text{ 的 } 1-\alpha \text{ 置信区间 } \left[\bar{X} - \frac{S}{\sqrt{n}} t_{1-\alpha/2}(n-1), \bar{X} + \frac{S}{\sqrt{n}} t_{1-\alpha/2}(n-1) \right]$$

计算此次抽样样本均值与样本方差的取值

$$\bar{x} = \frac{7.32 + 7.37 + 7.24 + 7.41 + 7.33 + 7.38 + 7.36 + 7.42 + 7.21}{9} = 7.338,$$

$$s^2 = \frac{1}{8} \sum_{i=1}^9 (x_i - \bar{x})^2 = 5.19 \times 10^{-3}, \quad s = \sqrt{5.19 \times 10^{-3}} = 0.072.$$

查表得 $t_{0.975}(8) = 2.306$ ，得到 μ 的置信系数 0.95 的区间估计为 $[7.282, 7.393]$ 。

15.3 两个正态总体的区间估计

两个正态总体 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, μ_1 、 μ_2 未知, σ_1^2 、 σ_2^2 未知, X_1, \dots, X_m

和 Y_1, \dots, Y_n 分别是来自两个总体的样本, 且假设这两个样本相互独立, 求 $\mu_2 - \mu_1$

的 $1-\alpha$ 置信区间。

此问题被命名为贝伦斯-费舍尔 (Behrens-Fisher) 问题, 是统计学中至今没有完全解决的问题。

例 15.3.1 两个正态总体 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, μ_1 、 μ_2 未知, σ_1^2 、 σ_2^2 已

知, X_1, \dots, X_m 和 Y_1, \dots, Y_n 分别是来自两个总体的样本, 且假设这两个样本相互独立, 求 $\mu_2 - \mu_1$ 的 $1-\alpha$ 置信区间。

$$\text{解: } \bar{X} \sim N\left(\mu_1, \frac{\sigma_1^2}{m}\right), \quad \bar{Y} \sim N\left(\mu_2, \frac{\sigma_2^2}{n}\right) \Rightarrow \bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}\right)$$

$$G = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \sim N(0, 1), \quad P\left(-u_{1-\alpha/2} \leq \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \leq u_{1-\alpha/2}\right) = 1 - \alpha$$

$$\mu_2 - \mu_1 \text{ 的 } 1-\alpha \text{ 置信区间 } \left[\bar{X} - \bar{Y} - u_{1-\alpha/2} \cdot \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}, \bar{X} - \bar{Y} + u_{1-\alpha/2} \cdot \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}} \right]$$

例 15.3.2 两个正态总体 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, μ_1 、 μ_2 未知, σ_1^2 、 σ_2^2 未知但相等, 即 $\sigma_1^2 = \sigma_2^2 = \sigma^2$, X_1, \dots, X_m 和 Y_1, \dots, Y_n 分别是来自两个总体的样本, 且假设这两个样本相互独立, 求 $\mu_2 - \mu_1$ 的 $1-\alpha$ 置信区间。

$$\text{解: } \bar{X} \sim N\left(\mu_1, \frac{\sigma^2}{m}\right), \quad \bar{Y} \sim N\left(\mu_2, \frac{\sigma^2}{n}\right), \quad \bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \left(\frac{1}{m} + \frac{1}{n}\right)\sigma^2\right),$$

$$\text{标准化后 } \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sigma \sqrt{\left(\frac{1}{m} + \frac{1}{n}\right)}} \sim N(0, 1),$$

$$\frac{(m-1)S_x^2}{\sigma^2} \sim \chi^2(m-1), \quad \frac{(n-1)S_y^2}{\sigma^2} \sim \chi^2(n-1), \quad \frac{(m-1)S_x^2 + (n-1)S_y^2}{\sigma^2} \sim \chi^2(m+n-2)$$

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2) / \sigma \sqrt{\left(\frac{1}{m} + \frac{1}{n}\right)}}{\sqrt{\frac{(m-1)S_x^2 + (n-1)S_y^2}{\sigma^2}} / \sqrt{m+n-2}} = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\left(\frac{1}{m} + \frac{1}{n}\right)} \sqrt{\frac{(m-1)S_x^2 + (n-1)S_y^2}{m+n-2}}} \sim t(m+n-2)$$

$$\text{记 } S_w^2 = \frac{(m-1)S_x^2 + (n-1)S_y^2}{m+n-2},$$

$$P\left(-t_{1-\alpha/2}(m+n-2) \leq \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_w \sqrt{\left(\frac{1}{m} + \frac{1}{n}\right)}} \leq t_{1-\alpha/2}(m+n-2)\right) = 1 - \alpha$$

得到 $\mu_2 - \mu_1$ 的 $1 - \alpha$ 置信区间

$$\left[\bar{X} - \bar{Y} - \sqrt{\frac{1}{m} + \frac{1}{n}} S_w t_{1-\alpha/2}(m+n-2), \bar{X} - \bar{Y} + \sqrt{\frac{1}{m} + \frac{1}{n}} S_w t_{1-\alpha/2}(m+n-2) \right].$$

例 15.3.3 两个正态总体 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, μ_1 、 μ_2 未知, σ_1^2 、 σ_2^2 未知, X_1, \dots, X_m 和 Y_1, \dots, Y_n 分别是来自两个总体的样本, 假设这两个样本相互独立, 求 σ_1^2 / σ_2^2 的 $1 - \alpha$ 置信区间。

解: $\frac{(m-1)S_x^2}{\sigma_1^2} \sim \chi^2(m-1)$ 和 $\frac{(n-1)S_y^2}{\sigma_2^2} \sim \chi^2(n-1)$, 两者相互独立,

故构造 F 分布枢轴量 $F = \frac{S_x^2 / \sigma_1^2}{S_y^2 / \sigma_2^2} \sim F(m-1, n-1)$,

$$\sigma_1^2 / \sigma_2^2 \text{ 的 } 1 - \alpha \text{ 置信区间 } \left[\frac{S_x^2}{S_y^2} \frac{1}{F_{1-\alpha/2}(m-1, n-1)}, \frac{S_x^2}{S_y^2} \frac{1}{F_{\alpha/2}(m-1, n-1)} \right].$$

15.4 大样本置信区间

样本容量足够大时, 根据中心极限定理可以利用渐近正态分布构造置信区间。

例 15.4.1 贝伦斯-费舍尔 (Behrens-Fisher) 问题, 样本 X_1, \dots, X_m 来自正态总体 $N(\mu_1, \sigma_1^2)$, 样本 Y_1, \dots, Y_n 来自正态总体 $N(\mu_2, \sigma_2^2)$, μ_1 、 μ_2 未知, σ_1^2 、 σ_2^2

未知，且假设这两个样本相互独立，求 $\mu_2 - \mu_1$ 的 $1-\alpha$ 置信区间。

$$\text{解: } \bar{X} \sim N\left(\mu_1, \frac{\sigma_1^2}{m}\right), \quad \bar{Y} \sim N\left(\mu_2, \frac{\sigma_2^2}{n}\right) \Rightarrow \bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}\right)$$

$$\frac{\bar{X} - \bar{Y} - (\mu_2 - \mu_1)}{\sqrt{\sigma_1^2/m + \sigma_2^2/n}} \sim N(0, 1)$$

$$\text{当 } m \text{ 和 } n \text{ 较大时, } S_x^2 \approx \sigma_1^2, \quad S_y^2 \approx \sigma_2^2$$

$$\text{有如下近似 } \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{S_x^2/m + S_y^2/n}} \sim N(0, 1), \text{ 以此作为枢轴量,}$$

可得到 $\mu_2 - \mu_1$ 的 $1-\alpha$ 置信水平的

$$\text{近似区间估计 } \left[\bar{X} - \bar{Y} - u_{1-\alpha/2} \sqrt{S_x^2/m + S_y^2/n}, \bar{X} - \bar{Y} + u_{1-\alpha/2} \sqrt{S_x^2/m + S_y^2/n} \right]。$$

例 15.4.2 样本 X_1, \dots, X_n 来自两点分布总体 $b(1, p)$ ，求 p 的区间估计。

$$\text{解: 样本均值的期望、方差分别为 } E(\bar{X}) = p, \quad \text{Var}(\bar{X}) = \frac{p(1-p)}{n}$$

根据中心极限定理当 n 较大时，有近似分布

$$\bar{X} \sim N\left(p, \frac{p(1-p)}{n}\right), \quad \text{标准化后得到枢轴量 } \frac{\bar{X} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1),$$

$$P\left(\left|\frac{\bar{X} - p}{\sqrt{p(1-p)/n}}\right| \leq u_{1-\frac{\alpha}{2}}\right) \approx 1-\alpha, \quad \text{即 } (\bar{X} - p)^2 \leq u_{1-\frac{\alpha}{2}}^2 \frac{p(1-p)}{n}$$

$$P\left(\left|\frac{\bar{X} - p}{\sqrt{p(1-p)/n}}\right| \leq u_{1-\frac{\alpha}{2}}\right) \approx 1-\alpha, \quad \text{即 } (\bar{X} - p)^2 \leq u_{1-\frac{\alpha}{2}}^2 \frac{p(1-p)}{n}, \text{ 解得}$$

$$\frac{1}{1+c} \left(\bar{X} + \frac{c}{2} - \sqrt{\frac{\bar{X}(1-\bar{X})}{n} u_{1-\frac{\alpha}{2}}^2 + \frac{c^2}{4}} \right) \leq p \leq \frac{1}{1+c} \left(\bar{X} + \frac{c}{2} + \sqrt{\frac{\bar{X}(1-\bar{X})}{n} u_{1-\frac{\alpha}{2}}^2 + \frac{c^2}{4}} \right)$$

其中 $c = \frac{u_{1-\frac{\alpha}{2}}^2}{n}$, 当 n 较大时, c 的值很小可略去, 得到参数 p 的 $1-\alpha$ 置信水平

$$\text{的近似估计区间} \left[\bar{X} - u_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}, \bar{X} + u_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \right]。$$

例 15.4.3 一个网络产品的运营商希望了解该产品在某个城市的用户占有率, 进行了随机抽样调查, 样本容量为 500, 调查结果有 84 人是该产品的用户, 求这个网络产品在该城市占有率的一个 95% 置信区间。

解: 总体分布 $X \sim b(1, p)$, 样本均值 $\bar{X} = \frac{X_1 + \cdots + X_{500}}{500}$

$$\text{期望、方差分别为 } E(\bar{X}) = p, \text{ Var}(\bar{X}) = \frac{p(1-p)}{n} = \frac{p(1-p)}{500}$$

$$\frac{(\bar{X} - p)}{\sqrt{\frac{p(1-p)}{500}}} \sim N(0, 1), \left[\bar{X} - u_{0.975} \sqrt{\frac{\bar{X}(1-\bar{X})}{500}}, \bar{X} + u_{0.975} \sqrt{\frac{\bar{X}(1-\bar{X})}{500}} \right]$$

$$\bar{x} = \frac{84}{500} = 0.168, \quad u_{0.975} = 1.96, \quad \text{近似估计区间为: } [0.135, 0.201]。$$

例 15.4.4 一个网络产品的运营商希望了解该产品在某个城市的用户占有率, 进行了随机抽样调查, 样本容量为 500, 调查结果有 84 人是该产品的用户。根据抽样调查的信息, 运营商希望得到参数 p 的 95% 置信水平的区间估计, 且估计区间长度不超过 0.02, 问至少需要多大的样本容量?

$$\text{解: 参数 } p \text{ 的 } 1-\alpha \text{ 置信区间为 } \left[\bar{X} - u_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}, \bar{X} + u_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \right]$$

$$\text{估计区间长度不超过 0.02, 即 } u_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}} \leq 0.01。$$

$$n \geq \left(\frac{u_{1-\alpha/2}}{0.01} \right)^2 \bar{x}(1-\bar{x}) = \left(\frac{u_{0.975}}{0.01} \right)^2 \bar{x}(1-\bar{x}) = \left(\frac{1.96}{0.01} \right)^2 0.168(1-0.168) = 5369.6$$

例 15.4.5 一个网络产品的运营商希望了解该产品在某个城市的用户占有率，希望得到参数 p 的 95% 置信水平，且估计区间长度不超过 0.02 的区间估计，问在没有任何先验知识的情况下，至少需要多大的样本容量才能保证达到所希望的估计精度？

解：参数 p 的 $1-\alpha$ 置信区间为 $\left[\bar{X} - u_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}, \bar{X} + u_{1-\frac{\alpha}{2}} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \right]$

对任何 $\bar{X} \in (0,1)$ ， $\bar{x}(1-\bar{x}) \leq \frac{1}{4}$

$$n \geq \left(\frac{u_{1-\alpha/2}}{0.01} \right)^2 \frac{1}{4} \geq \left(\frac{u_{1-\alpha/2}}{0.01} \right)^2 \bar{x}(1-\bar{x}), \quad n \geq \left(\frac{u_{0.975}}{0.01} \sqrt{\frac{1}{4}} \right)^2 = 9604$$

问题没有变，可是现在这个情况下估计的所需样本容量数比上一题多了不少。因为本题中先验信息少于上一题，所以得到估计不如上题精确也是很自然的。一般而言，得到信息越多，越有可能得到更好的估计。
